

TUGAS KELOMPOK — MACHINE LEARNING

Analisis & Implementasi Decision Tree dan Naive Bayes untuk Prediksi Kelulusan Tepat Waktu Mahasiswa

Bagian B & C — Rekomendasi & Etika Penggunaan Model

Kelompok:

1. Muhammad Nathan Algibran
(G1A024057)
2. Muhammad Abel Cakrawangsa
(G1A024077)

Program Studi Informatika

Repositori Github : <https://github.com/Nathan-Algibran/TUGAS-MACHINE-LEARNING>

■ Latar Belakang & Dataset

Prediksi status kelulusan tepat waktu mahasiswa dari data akademik & aktivitas belajar

Fitur dataset

IPK, Kehadiran, Jam_Belajar, Organisasi, Penghasilan_Ortu, Jenis_Kelamin, dan Status_Beasiswa — target: Lulus_Tepat_Waktu (Ya/Tidak).

Praproses

Pembersihan data, encoding fitur kategorikal, lalu split 80:20 menjadi data latih dan data uji.

Model yang dibandingkan

Decision Tree (max_depth=3), Decision Tree (tanpa batas kedalaman), dan Gaussian Naive Bayes.

500

data mahasiswa (400 latih · 100 uji)

61% / 39%


sebaran kelas Lulus vs Tidak — relatif seimbang

7

fitur akademik & sosio-demografis

Distribusi kelas sedikit tidak seimbang (61% Ya, 39% Tidak) ini salah satu penyebab recall kelas 'Tidak' lebih rendah di ketiga model.


Hasil Evaluasi 3 Model



Akurasi · Precision · Recall · F1


Model	Akurasi	F1
DT (depth=3)	0.65	0.74
DT (depth=None)	0.65	0.72
Gaussian NB	0.76	0.82

Gaussian Naive Bayes tampil terbaik di semua metrik (akurasi 76%, F1 0.82). Kedua Decision Tree sama-sama di akurasi 0.65 meski kedalamannya beda jauh — depth=3 malah sedikit unggul di recall (0.84 vs 0.74), sementara depth=None sedikit unggul di precision (0.70 vs 0.67), menunjukkan trade-off klasik



Struktur Decision Tree & Fitur Penentu

Decision Tree (max_depth=3) - Prediksi Kelulusan Tepat Waktu



Decision Tree (max_depth=3) — akar pemisah: $IPK \leq 2.885$

Pola pemisah

IPK jadi pemisah pertama (memisahkan 400 data jadi 148 vs 252), diikuti Kehadiran di level kedua (ambang 69.95 / 80.35 tergantung cabang), lalu Jam_Belajar atau IPK lagi di level ketiga. Semuanya fitur akademik — bukan Nilai_Tugas atau Partisipasi_Diskusi.

Catatan fairness

Penghasilan_Ortu dan Jenis_Kelamin sama sekali tidak muncul di pohon dangkal ini. Tetap perlu audit keadilan sebelum dipakai untuk keputusan resmi seperti beasiswa, mengingat Penghasilan_Ortu secara historis berkorelasi dengan Status_Beasiswa.

■ Simulasi Prediksi & Kesimpulan

... Jumlah data salah prediksi: 35 dari 100 data test

	IPK	Kehadiran	Jam_Belajar	Organisasi	Aktual	Prediksi
4	2.89	57.3	6.0	0	Tidak	Ya
6	2.04	74.1	12.8	1	Tidak	Ya
8	2.63	98.6	4.6	1	Ya	Tidak
11	1.54	100.0	9.7	1	Tidak	Ya
12	2.44	87.3	9.0	0	Tidak	Ya

Contoh 5 dari 35 data salah prediksi Decision Tree (depth=3) pada 100 data uji.

Model sesekali salah pada kasus borderline dekat ambang split — mis. mahasiswa dengan IPK 2.63 dan Kehadiran sangat tinggi (98.6%) justru diprediksi 'Tidak', karena jalur split IPK ≤ 2.905 di cabang itu tidak lagi mempertimbangkan Kehadiran-nya.

Gaussian Naive Bayes

Rekomendasi utama, unggul di semua metrik (akurasi 76%, recall 90%) & ringan secara komputasi.

Decision Tree (depth=3)

Pilih jika aturan perlu mudah dijelaskan ke pihak kampus, meski akurasi lebih rendah.

Langkah lanjut

Keluarkan Penghasilan_Ortu & Jenis_Kelamin dari model bila dipakai untuk keputusan beasiswa; audit fairness per subgrup sebelum dipakai institusional.